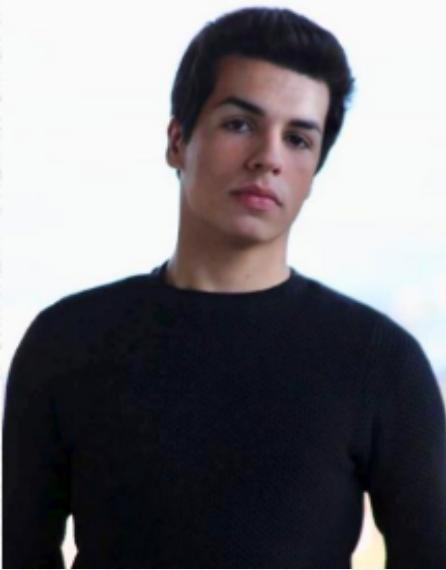


SISTEMA INTELIGENTE DE SUPORTE À TOMADA DE DECISÃO PARA AS LOJAS FAVORITA

GRUPO 5 - TP1

TÉCNICAS DE INTELIGÊNCIA ARTIFICIAL NA PREVISÃO E
OTIMIZAÇÃO EM SISTEMAS EMPRESARIAIS

Equipa Técnica



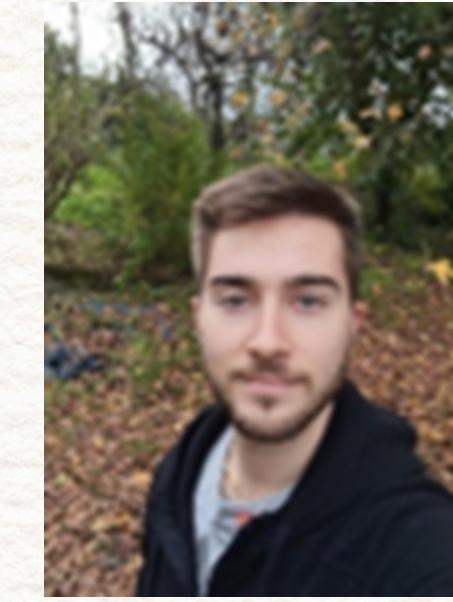
PEDRO PIRES



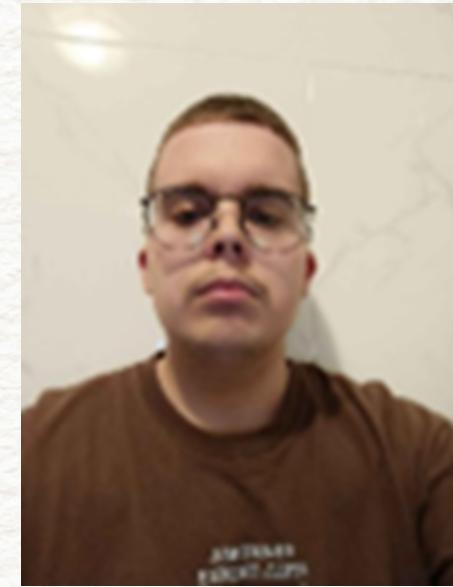
LUCAS PEREIRA



MIGUEL MIRANDA



JOÃO AFONSO



JOSÉ SILVA

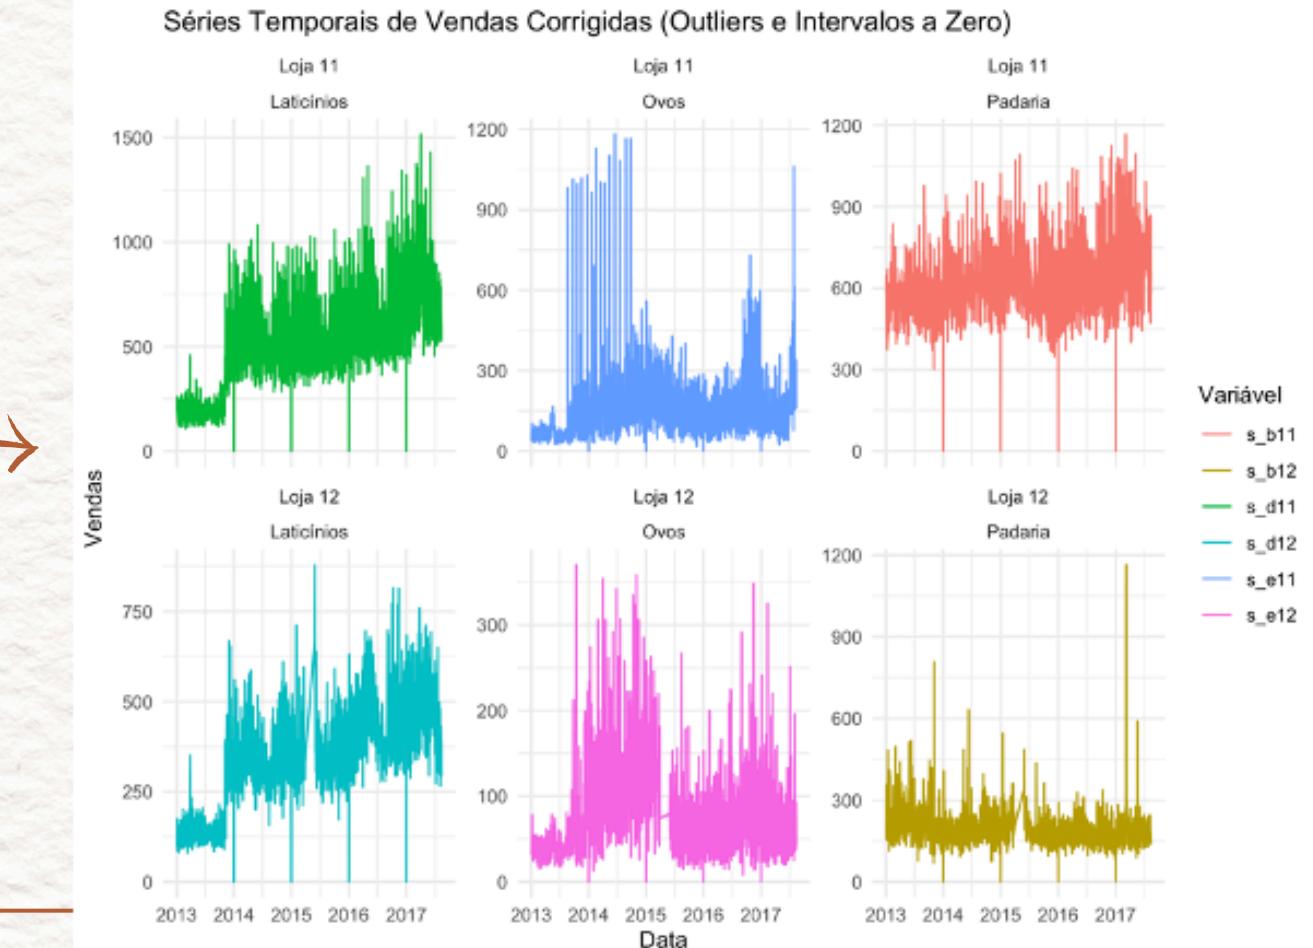
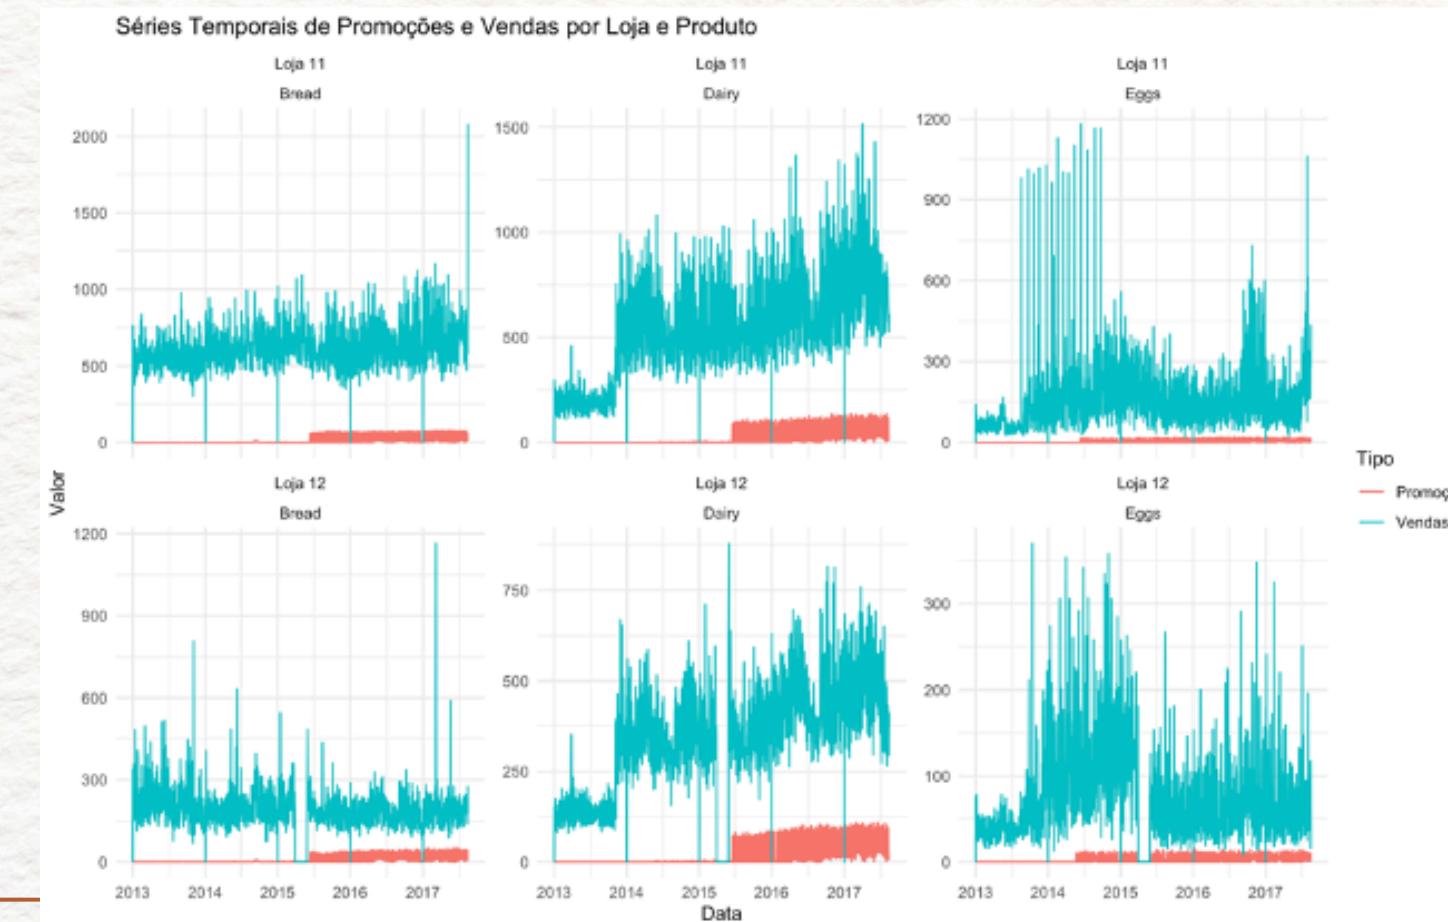
Abordagem Metodológica

CRISP-DM



Preparação de Dados

- Tratamento dos Outliers recorrendo à média móvel e z-score local (outlier = zscore absolutamente >2.5)
- Tratamento do tempo sem vendas da loja 12 recorrendo a interpolação linear . Para preenchimento dos valores das extremidades, estendemos o valor mais próximo.



Previsão

Previsão

CENÁRIO COM TODOS OS DADOS

Univariados
Holt-Winters.
XGBoost
Random Forest
Redes Neuronais
ARIMA

Multivariados
XGBoost
Random Forest
ARIMAX

Tuning aplicado aos
modelos univariados

CENÁRIO COM OS DADOS DO ÚLTIMO ANO

-> **Growing Window**
-> **Rolling Window**

Modelos:
Holt-Winters.
XGBoost
Random Forest
Redes Neuronais
ARIMA

Tuning aplicado aos
modelos

AVALIAÇÃO COM O SNAIVE

-> A melhoria percentual do NMAE dos nossos modelos em relação ao SNAIVE é percebido como lucro

-> Foi aqui garantido o critério de sucesso de negócio de obter uma melhoria do lucro semanal entre os 10 e os 15 %

Método de Comparação: NMAE

Previsão

Resultados Obtidos

Cenário com Todos os Dados

Loja	Produto	Métrica	Univariados				Multivariados			
			Redes Neuronais	Random Forest	Arima	Holt Winters	XGBoost	XGBoost	Random Forest	ARIMAX
11	Laticínios (s_d11)	MAE	49.715	67.764	49.631	93.29	59.709	201.200	177.39252	48.690
		NMAE	30.879	26.063	19.089	94.232	22.965	203.232	179.18437	49.181
		RMSE	67.624	76.260	67.977	109.942	70.413	204.616	192.95930	79.551
		RRSE	118.938	96.510	86.028	274.368	89.110	510.636	481.54520	198.526
	Ovos (s_e11)	MAE	44.8022	104.725	84.204	151.621	72.851	96.794	87.58205	86.410
		NMAE	32.465	59.167	47.573	85.662	41.159	54.686	49.48138	48.819
		RMSE	60.692	111.092	100.026	180.421	95.024	119.757	107.09559	87.825
		RRSE	100.818	157.155	141.499	302.693	134.424	200.617	179.67500	147.345
	Padaria (s_b11)	MAE	124.503	96.089	115.689	97.456	79.060	287.535	110.29176	66.688
		NMAE	53.665	24.265	29.214	24.61	19.965	72.610	27.85146	16.840
		RMSE	148.745	128.611	130.468	135.703	118.309	309.006	127.67735	114.851
		RRSE	169.495	113.370	115.007	120.232	104.289	273.777	113.12130	101.758
12	Laticínios (s_d12)	MAE	26.502	54.529	46.546	115.299	41.863	126.605	120.92000	33.858
		NMAE	39.555	39.230	33.486	123.978	30.118	136.135	130.02151	36.406
		RMSE	31.173	69.799	61.642	118.571	52.128	136.637	128.63354	35.867
		RRSE	112.242	154.086	136.079	319.822	115.077	368.552	346.96320	96.744
	Ovos (s_e12)	MAE	33.628	25.113	19.120	36.12	22.231	23.309	25.91912	10.239
		NMAE	86.227	45.660	34.764	66.889	40.421	43.165	47.99837	18.961
		RMSE	37.117	31.243	22.269	49.694	27.095	29.933	29.09230	13.320
		RRSE	266.481	162.255	115.652	274.884	140.714	165.576	160.92600	73.681
	Padaria (s_b12)	MAE	13.122	24.225	30.393	49.673	13.147	54.522	45.01336	19.492
		NMAE	18.224	22.854	28.673	118.268	12.403	129.813	107.17466	46.410
		RMSE	17.442	31.904	35.104	59.672	21.106	58.066	54.57687	21.347
		RRSE	62.653	83.674	92.065	345.505	55.353	336.206	316.00390	123.602

Rolling Window

Loja	Produto	Métrica	Univariados					
			Redes Neuronais	Random Forest	Arima	Holt Winters	XGBoost	RRSE
11	Laticínios (s_d11)	MAE	229.494	160.752	161.761	113.36	113.473	
		NMAE	12.749	10.611	10.677	7.483	7.490	
		RMSE	254.754	195.783	193.160	136.07	142.173	
		RRSE	448.062	183.732	114.710	73.061	133.638	
	Ovos (s_e11)	MAE	98.202	117.337	88.305	89.26	113.101	
		NMAE	13.864	11.049	8.315	8.405	10.650	
		RMSE	133.858	153.225	109.718	105.9	150.053	
		RRSE	222.358	146.780	83.732	77.803	142.387	
	Padaria (s_b11)	MAE	164.058	89.683	89.104	97.23	89.054	
		NMAE	10.309	7.692	7.642	8.339	7.638	
		RMSE	191.099	106.803	110.604	121.03	105.180	
		RRSE	217.758	114.429	96.246	92.009	113.197	
12	Laticínios (s_d12)	MAE	187.949	71.047	87.168	79.62	64.929	
		NMAE	11.388	8.717	10.699	9.769	7.967	
		RMSE	193.728	85.037	102.797	98.59	79.240	
		RRSE	697.536	123.329	121.395	78.503	108.038	
	Ovos (s_e12)	MAE	50.614	25.418	41.428	46.49	24.535	
		NMAE	13.907	7.304	11.904	12.358	7.050	
		RMSE	58.707	33.018	58.402	59.17	33.529	
		RRSE	421.492	100.546	192.821	174.488	100.115	
	Padaria (s_b12)	MAE	84.765	23.577	41.138	34.24	21.605	
		NMAE	3.917	2.025	3.534	2.941	1.856	
		RMSE	98.071	27.952	50.582	44.94	26.346	
		RRSE	352.288	92.299	119.622	85.673	86.852	

Growing Window

Loja	Produto	Métrica	Univariados					
			Redes Neuronais	Random Forest	Arima	Holt Winters	XGBoost	RRSE
11	Laticínios (s_d11)	MAE	101.360	99.001	84.533	236.57	88.718	
		NMAE	10.193	6.535	5.981	15.615	5.856	
		RMSE	124.219	116.152	113.83	283.96	108.772	
		RRSE	218.477	98.939	69.063	155.394	100.559	
	Ovos (s_e11)	MAE	44.661	90.446	78.108	111.44	85.182	
		NMAE	9.043	8.517	7.355	10.494	8.021	
		RMSE	53.275	117.104	93.106	138.01	114.152	
		RRSE	88.498	118.497	62.354	164.925	114.037	
	Padaria (s_b11)</							

Otimização

Otimização

Modelos De Otimização

O1

MonteCarlo

PSO

Hill Climbing

Genetic Algorithm

Simulated Annealing

Differential Evolution

O2

SPEA-II

NSGA-II

Hill Climbing com Pesos

Genetic Algorithm com Pesos

Simulated Annealing com Pesos

Otimização

Objetivo 1 - Fase 1 + 2

- Definição das funções Lower, Upper, Repair e Eval
- Fase 1 - Utilizamos apenas a última semana prevista como previsões
- Fase 1 - Realizamos os algoritmos de modo a maximizar o lucro, aplicando tuning para melhorar os modelos.
- Fase 1 - Análise de Convergência
- Fase 2 - Usamos as previsões resultantes do Growing Window
- Fase 2 - Voltamos a realizar os algoritmos para maximizar o lucro
- Fase 2 - Análise de convergência por iteração

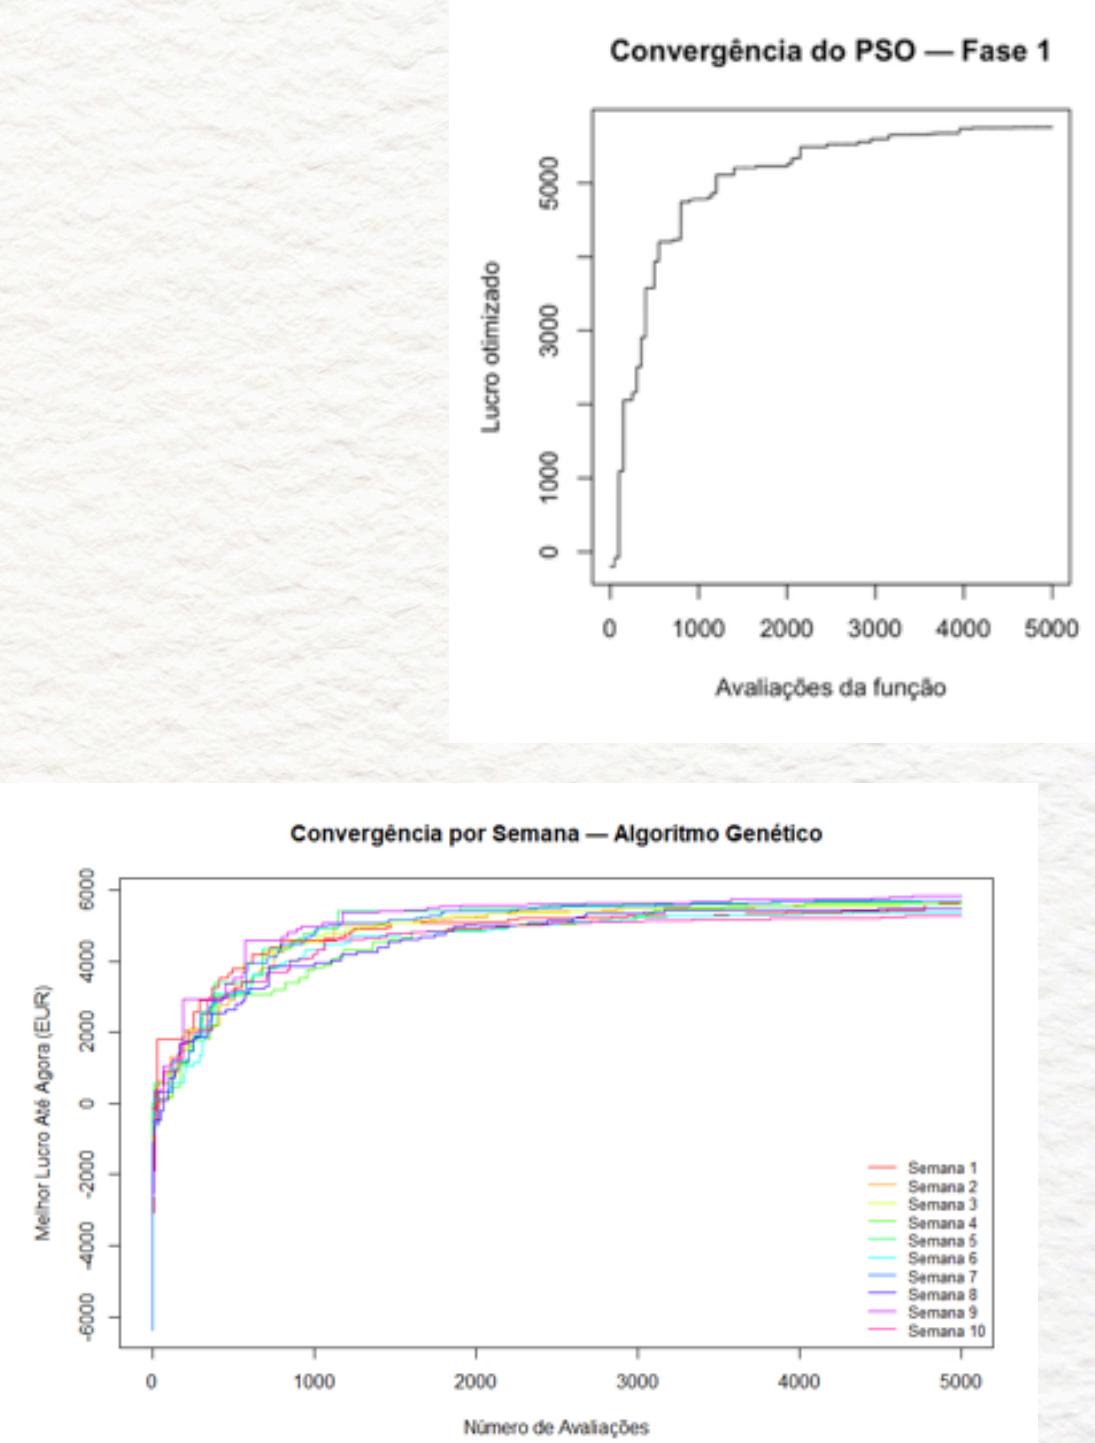
Resultados Obtidos

```

> source("~/Desktop/Mestrado/TIPOSE/Projeto/Previsao+Optimizacao/Otimizacao/Objetivo.R")
> Forecasted sales:
   [,1] [,2] [,3] [,4] [,5] [,6]
[1,] 626 366 177 38 472 181
[2,] 575 341 340 92 868 175
[3,] 608 387 163 65 634 145
[4,] 527 294 170 43 582 139
[5,] 569 381 338 45 582 184
[6,] 603 411 275 117 583 275
[7,] 611 373 438 15 2080 176
> Distributed products per day:
  wd1 wd2 we1 we2 wb1 wb2
[1,] 200 150 175 50 990 500
[2,] 100 64 300 20 155 101
[3,] 0 0 0 0 0 0
[4,] 700 300 100 35 200 23
[5,] 200 234 140 78 100 75
[6,] 100 50 8 230 300 23
[7,] 0 0 0 0 0 0
> Warehousing resources: 10 4 0 7 4 4 0
> total Warehousing resources cost= 345
check if Warehousing resources can distribute all products:
[1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE
>Vehicle resources per day:
  v1 v2 v3
[1,] 11 0 0
[2,] 0 1 2
[3,] 0 0 0
[4,] 4 2 0
[5,] 0 3 0
[6,] 0 2 1
[7,] 0 0 0
> vehicle total cost= 1258
check if vehicles can distribute all products:
[1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE
[1] "True sales:"
   [,1] [,2] [,3] [,4] [,5] [,6]
[1,] 200 150 175 38 472 181
[2,] 100 64 300 32 673 175
[3,] 0 0 0 0 0 145
[4,] 527 294 100 35 200 123
[5,] 373 240 140 45 100 75
[6,] 100 50 8 117 300 23
[7,] 0 0 0 15 0 0
> total sales revenue= 3093.9
[1] "Stock:"
   [,1] [,2] [,3] [,4] [,5] [,6]
[1,] 0 0 0 12 518 319
[2,] 0 0 0 0 0 245
[3,] 0 0 0 0 0 100
[4,] 173 6 0 0 0 0
[5,] 0 0 0 33 0 0
[6,] 0 0 0 146 0 0
[7,] 0 0 0 131 0 0
> total stock cost= 93.1
[1] "Total costs:"
> total costs= 345 + 1258 + 93.1 = 1696.1
>> Week profit= 3093.9 - 1696.1 = 1397.8 EUR
>> Week resources= 29 + 26 = 55
[1] 1397.8

```

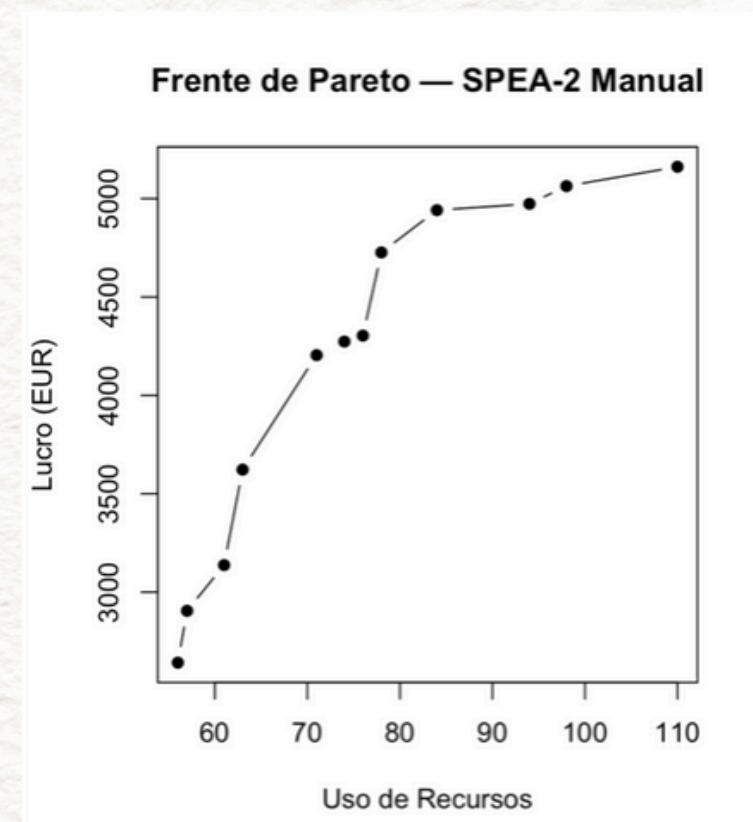
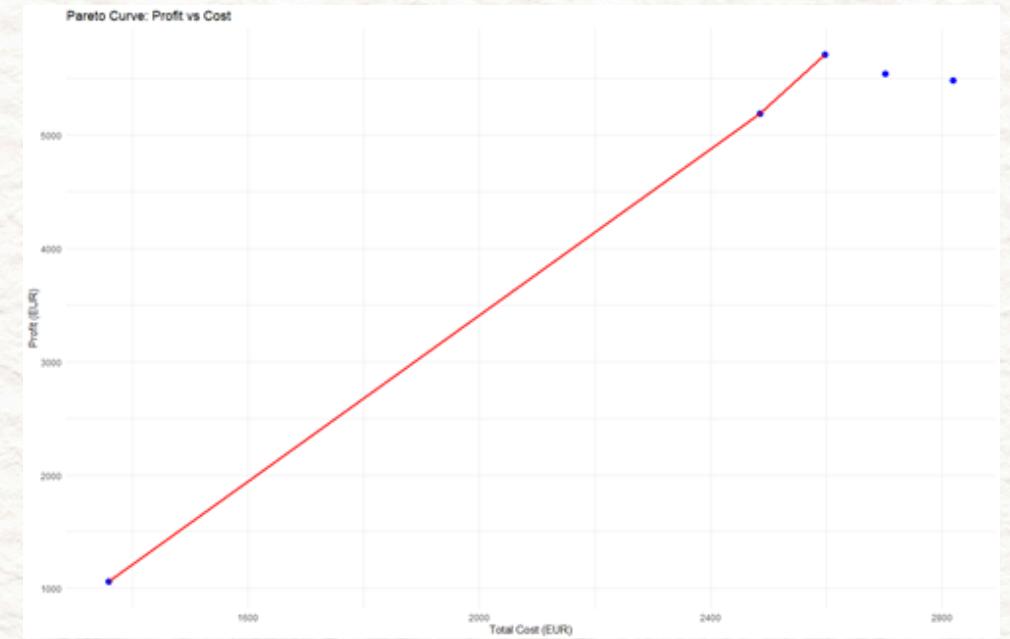
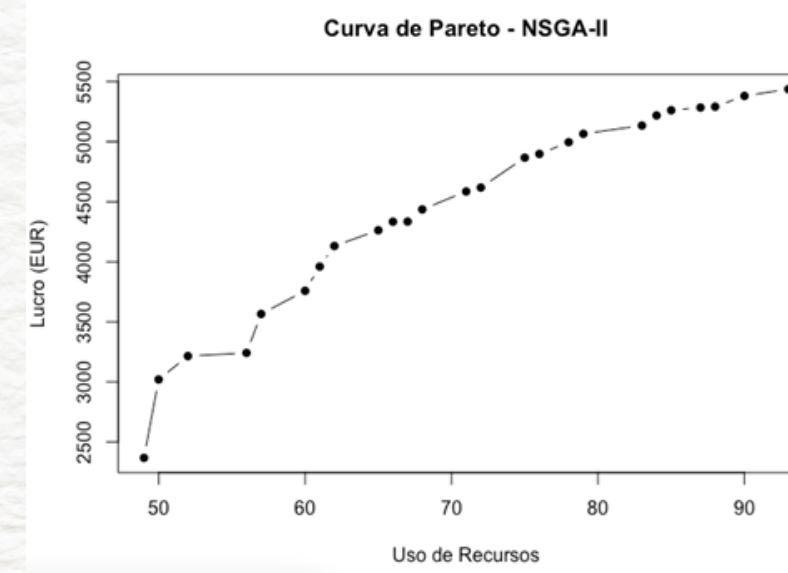
Modelo	Lucro	Melhor Solução
Hill Climbing	6372.35	Recursos de Armazenagem
		N+1 N+2 N+3 N+4 N+5 N+6 N+7
		13 12 12 10 10 10 9
		Custo Total de Armazém: 885
		Veículos por Dia
		Dia V1 V2 V3
		1 0 1 6
		2 1 0 6
		3 1 0 6
		4 1 0 5
		5 1 0 5
		6 1 0 5
		7 1 0 5
		Custo Total de Veículos: 2558
		Distribuição de Produtos por Dia
		Dia s_d11 s_d12 s_e11 s_e12 s_b11 s_b12
		1 0 0 0 0 20 0
		2 8 0 0 0 34 0
		3 12 7 12 0 12 2
		4 0 9 15 31 0 0
		5 11 0 44 31 0 0
		6 3 24 38 19 16 0
		7 3 8 48 11 6 9
		Custo Stock: 24.65
Hill Climbing	6345.01	Iteração Lucro
		1 6641.066
		2 6404.629
		3 6694.971
		4 6183.137
		5 6579.364
		6 6231.343
		7 6340.514
		8 6195.226
		9 6202.682
		10 6349.515



Otimização Objetivo 2

- Realização de algoritmos de otimização multiobjetivos
- Realização de algoritmos de otimização com pesos
- Exploração das curvas de pareto

Resultados Obtidos



Interface